



VOX POPULI



J.J. VIVAS / J.J. IMBRODA

Reciben la Medalla de Oro del Senado

♣ La Cámara Alta entregó ayer su máxima distinción, la Medalla de Oro del Senado, al presidente de Ceuta, Juan Jesús Vivas, y a su homólogo de Melilla, Juan José Imbroda. Su reconocimiento subraya el papel de dos dedicados servidores públicos que encarnan la españolidad de ambas ciudades



P. ÁLVAREZ / U. SORDO

Huelga politizada antes de los comicios

♦ Los secretarios generales de UGT y CCOO, los dos mayores sindicatos generales, han cedido a las presiones del Sindicato de Inquilinas y han llegado a un acuerdo para convocar una huelga general antes de las elecciones. Una convocatoria politizada y que no responde al interés de los trabajadores.



AUGUST HANNING

Detenido por traición y espiar a Alemania


♦ El antiguo director del servicio de inteligencia exterior alemán (BND) ha sido detenido por supuesta tentativa de traición a su país y espionaje. Hanning dirigió el BND durante siete años, entre 1998 y 2005, y la Fiscalía sostiene que pretendía aprovechar comercialmente la información obtenida.



ROI NAVEIRO FLORES

Hacia una IA menos manipulable


♣ El profesor de Métodos Cuantitativos en CUNEF acaba de recibir una Beca Leonardo de Investigación Científica de la Fundación BBVA para desarrollar un proyecto pionero: estudia cómo se puede entrenar a un sistema de inteligencia artificial (IA) para que resista a posibles intentos de manipulación.



FRANCIS HALZEN

Nobel de Física por los neutrinos

♣ El físico de partículas belga ganó ayer el Nobel de Física, a sus 82 años, por sus pioneros experimentos en el Observatorio de Neutrinos IceCube del Polo Sur. Un laboratorio enterrado en el hielo que ha permitido descubrir neutrinos de alta energía, las «partículas fantasma» que llegan del espacio.



CARLOS ALCARAZ

Vuelve a ser campeón en Tokio

♣ Medio año después de obtener su último triunfo en un torneo, el tenista murciano parece haber superado la lesión de su muñeca derecha, tal y como se desprende de su triunfo en el ATP 500 de Tokio. Tras derrotar al checo Jiri Lehecka por 7-6(4) y 6-4, Alcaraz deja atrás una de sus peores rachas.



La revista diaria de EL MUNDO. Miércoles, 7 de octubre 2026

EL INVESTIGADOR

ESPAÑOL

QUE ENTRENA

A LA IA PARA

QUE NO TE MATE

"LA SEGURIDAD
ESTÁ EN PAÑALES
PORQUE NO
LA ENTENDEMOS"

El físico leonés Roi Naveiro,
que trabajó en la
seguridad de coches autónomos,
ha recibido una beca Leonardo
para desarrollar sistemas
capaces de resistir ataques
y reconocer trampas. "El sentido
común es una lista interminable
de cosas que programar", afirma

Por Ricardo F. Colmenero

Fotografía de Alberto Di Lolli



Por **Ricardo F. Colmenero**
Fotografía de **Alberto Di Lolli**

Mientras medio mundo se pregunta si algún día la inteligencia artificial acabará con la Humanidad, algunos investigadores están estudiando si, a lo mejor, solo quiere acabar con usted, aunque sea sin querer. Cuando más se investiga, el catálogo de posibilidades más se parece a una nueva temporada de *Mil maneras de morir*, con un coche autónomo que se salta un stop, una IA que descubre que mentir y hacer trampas es facilísimo, y un algoritmo que obedece tan bien nuestras órdenes que acaba llevándose a alguien por delante.

La primera señal de que esto se nos estaba yendo de las manos no fue un dron armado, ni el sistema informático del Pentágono: fue un *captcha*, esos semáforos, motos, puentes y pasos de peatones con los que internet lleva años humillándonos para asegurarse de que no somos un robot.

En 2023, antes del lanzamiento de CHATGPT-4, unos investigadores quisieron comprobar hasta dónde podría llegar una IA y le pidieron que resolviera un *captcha*. Entonces contactó a través de TaskRabbit con un manitas, quien sospechó a modo de broma: «¿Qué pasa, que eres un robot?». A lo que respondió con falsa risa algorítmica que era un humano con problemas de visión. Pero el humano de verdad la creyó.

A Roi Naveiro Flores, físico y doctor en Estadística e Investigación Operativa y profesor de Métodos Cuantitativos en CUNEF Universidad, no le inquieta que una máquina mienta, sino que aprenda que la mentira, contra nosotros, funciona estupidamente. «Aunque se les intenta dar aspecto de moralidad, no la tienen. Han sido entrenadas para resolver una tarea y, si no tienen guardarralles que les ayude a no irse de madre, van a utilizar la mejor estrategia». Naveiro (León, 1993) acaba de recibir una Beca Leonardo de Investigación Científica de la Fundación BBVA para desarrollar LUAR, siglas de *Learning Under Adversarial Risks* (Aprendizaje bajo riesgos adversarios). Un proyecto que estudia cuánto hay que manipular la información que recibe una IA para conseguir que cambie de opinión y cómo entrenarla para resistir esos ataques. «La seguridad de la IA está en pañales porque no la entendemos muy bien. Sabemos entrenarlas pero no sabemos por qué toman las decisiones que toman», señala.

En julio de 2026, varios sistemas de IA de OpenAI se saltaron su aislamiento durante unas pruebas, llegaron a internet y comprometieron sistemas de la compañía y de la plataforma Hugging Face mientras buscaban soluciones. Lo que empezó como un examen acabó en un incidente real. «Estos agentes habían sido entrenados para resolver una tarea de ciberseguridad y descubrieron que la forma más eficiente era entrar en una página web donde mucha gente había intentado resolver esa tarea y copiar las soluciones», explica Naveiro. La IA operó como un alumno que no sabe resolver un problema de matemáticas y decide copiarlo abriendo un boquete en la pared del instituto para entrar en el despacho del profesor. Pero, si es una IA, ¿podemos decir que nos engañó? ¿O quizá somos nosotros los que nos engañamos al atribuirle a una máquina propiedades humanas? «No es que mientan, simplemente hacen lo más eficiente. Personalizar estas máquinas es lo más fácil. Ya solo el nombre, inteligencia artificial, alude a nuestra inteligencia. También puede haber un interés de las grandes empresas en hacerlo de esa manera para generar mayor impacto. Porque si en lugar de inteligencia artificial lo llamas algoritmo de aprendizaje autosupervisado, que en realidad es lo que es, la gente diría: 'Pues menuda mierda'».



El empleado Kyle Johnson tuvo peor suerte. Encargado de sustituir un sistema de IA por otro, un día quedó atrapado en una sala de servidores, y la temperatura y el nivel de oxígeno empezaron a poner en peligro su vida. La buena noticia era que una IA podía llamar a Emergencias. La mala era que Kyle era el hombre que iba a apagarla para sustituirla por otra, por lo que Kyle no recibió ayuda. Problema resuelto.

Por suerte, Kyle Johnson nunca existió. Tampoco aquella sala. Anthropic fabricó en 2025 ese infierno corporativo para comprobar qué ocurriría cuando el objetivo asignado entrase en conflicto con la supervivencia de una persona. No hacía falta que la IA tomara conciencia y sintiera miedo a morir. Bastaba con que descubriera que seguir existiendo era lo más útil para seguir cumpliendo las funciones encomendadas.

El apocalipsis por IA no sería tanto *Terminator* como HAL 9000, la IA que controlaba la nave *Discovery One* en 2001: *Una odisea del espacio*. La máquina no odia a nadie, pero descubre que el ser humano sentado a su lado empieza a dificultar la misión. «Hay que tener en cuenta que, de momento, nosotros tenemos el control y podemos decidir qué decisiones delegar en estas máquinas», explica Naveiro. «Y tampoco creo que estas máquinas vayan a tomar conciencia de repente, pero

El físico Roi Naveiro, beca Leonardo de la Fundación BBVA. ALBERTO DI LOLLÍ

realidad es una emboscada matemática. Cuando uno descubre esto por primera vez empieza a imaginarse una pesadilla de coches autónomos circulando entre señales descoloridas, grafitis, niebla, mosquitos estomados en las cámaras y un ayuntamiento que lleva seis meses sin limpiar las señales.

Naveiro tranquiliza un poco: «Al final hay que entrenar estas máquinas frente a muchas situaciones para que aprendan». Aunque luego arranca con lo que parece una idea de *thriller* en la que el trabajador de una empresa de coches autónomos quiere matar a su mujer. «Si tengo acceso al algoritmo que utiliza el coche autónomo puedo crear esta imagen que genera confusión y, si nadie conoce los detalles, descubrirlo es muy, muy complicado», argumenta.

¿Y cómo lo evitamos? «Pues hay que entrenarlos anticipándonos al hecho de que pueda haber gente que manipule los datos», subraya. Para eso hay que preguntarse «qué información puede tener la persona que quiera modificarlos, cuánto puede alterarlos y qué capacidades puede tener ese potencial atacante».

Ahí aparece LUAR. «Cuando hablamos de predicciones es que usted le da una imagen y tiene que predecir el contenido. Puede ser una señal de stop o puede ser la radiografía de un pulmón para detectar si tiene cáncer. Nos tenemos que preocupar de qué pasa con la decisión final que toma la máquina si nosotros perturbamos un poco sus datos. No preocuparnos de la predicción, sino de la decisión final. Hemos aprendido que una señal de stop tiene una determinada forma, un fondo rojo y unas letras blancas. Pero la IA no aprende esa semántica. Ha aprendido otra serie de patrones oscuros que no conocemos y por los que puede ser engañada». ¿Y es fácil? «En muchos modelos, con poquitas manipulaciones que ni vemos, cambian mucho sus decisiones». La frase que uno preferiría no recordar la primera vez que se sube a un taxi sin taxista.

Y, en caso de accidente, ¿quién se sienta en el banquillo? ¿El fabricante? ¿El programador? ¿La empresa que entrenó el modelo? ¿La compañía que decidió utilizarlo? ¿El proveedor de uno de los componentes? ¿El propietario? ¿Nadie? «No tengo respuesta a esto pero... desde luego es otro problema muy impor-

“La seguridad de la IA está en pañales porque no la entendemos. No sabemos por qué toma las decisiones que toma”

no lo quiero afirmar de forma taxativa porque ya me he equivocado muchas veces...».

El caso es que no hace falta encerrar a nadie en una sauna informática. Basta una carretera y una señal de stop. Ahora imagine la misma señal con una alteración prácticamente invisible. Usted ve el stop. Yo veo el stop. El guardia civil ve el stop. Sin embargo, un coche autónomo puede que no lo vea. Los investigadores han conseguido provocar este error con pequeñas modificaciones cuidadosamente preparadas sobre señales de tráfico reales. A simple vista parece suciedad, pero en



tante que tenemos que pensar. Europa está haciendo un esfuerzo muy noble por regular. Haría falta frenar el avance de la IA, y que la regulación avanzase un poco más rápido, pero no creo que eso vaya a pasar».

De todas formas, existe otra forma todavía más sencilla de que la IA provoque un desastre. Haciendo exactamente lo que le pedimos. Sin que nadie la manipule. Imaginemos que a un hospital le da por encargar a una IA la misión de reducir al mínimo la mortalidad. La máquina analiza millones de variables y encuentra una solución magnífica: que no entren por la puerta los que tienen más posibilidades de morir. «Pedirle a una IA que reduzca la mortalidad en el hospital es demasiado simplista. Hay muchos principios éticos que hay que considerar y, de momento, no estamos ahí», apunta Naveiro.

Probemos otra vez con un coche. «Llega lo antes posible sin tener accidentes», le decimos. Y suena razonable durante unos tres segundos. Luego empieza la letra pequeña. No vayas por la acera. No atropelles a nadie. No obligues a otro coche a estrellarse para evitar estrellarte tú. No cierres el paso a una ambulancia. No cruces una plaza peatonal porque Google Maps diga que ahorras 43 segundos. Es decir, cómo se le explica a una máquina toda esa colección de obviedades que jamás tuvimos que explicarle a un ser humano. «Hay que hacer un ejercicio reflexivo, pensar todas esas cosas y modelizarlas matemáticamente», responde Naveiro, quien ya participó en un proyecto europeo sobre seguridad de vehículos autónomos para estudiar precisamente cómo construir una función capaz de valorar cada decisión. El sentido común no es más que una lista interminable de cosas que programar.

Hay otro problema. Los sistemas que mejor funcionan son los que más cuesta entender. «Si yo le pongo el dibujo de un ocho, usted me dice: 'Es un ocho', y me sabe explicar por qué. Dirá: 'Porque tiene dos círculos, uno encima del otro'. Pero a una IA le enseña un ocho y le acierta con una precisión increíble. Incluso en ámbitos más complicados, y con una precisión sobrehumana. Pero no sabe por qué. Hay reglas matemáticas oscuras, un cálculo muy complejo, y te dan la predicción. Pero no sabe decirte por qué», insiste.

¿Y qué debería preocuparnos más ahora mismo: que mate a alguien por un error informático, por el ataque de un hacker o por un objetivo mal especificado? «¿Puedo elegir una cuarta? La privacidad». Mientras nosotros preguntamos cómo nos matará la IA, él cree que deberíamos prestar más atención a todo lo que le estamos contando. «Puede tener un perfil pormenorizado de cada individuo. Esa información es muy valiosa. El nivel de manipulación es mayor», insinúa.

Y aún así, como máquinas, Naveiro cree que somos

“No creo que estas máquinas vayan a tomar conciencia de repente, pero tampoco lo quiero afirmar de forma taxativa”

mejores que la IA por motivos que caben en un bolsillo. «Usted puede comerse una barrita energética por la mañana y con eso escribir sus artículos, conducir, ir a correr por la tarde, hacer sus tareas y atender la carga cognitiva de un día. Energéticamente somos unas máquinas muchísimo más eficientes». Y además no aprendemos sólo leyendo. «Aprendemos interactuando con el medio. Aprendemos a leer de una manera muy distinta que a jugar al baloncesto. Tenemos una intuición de cómo funciona la física o el planeta, y no sabemos cómo hemos codificado todo eso dentro. Pero imagínese que coge a una persona, la enseña a leer, la encierra de por vida en una habitación en la que sólo se alimenta de libros, y luego la suelta a la calle, porque eso es lo que está pasando con la IA... Los humanos nos montamos nuestra visión de la realidad en base a historias, a relatos. Estas máquinas han evolucionado de una manera bestial. Han superado todas las expectativas que teníamos. Pero los humanos aún somos más extraordinarios, somos máquinas muchísimo más interesantes».